

Dokumen Analisis Utama

Nama : Gregorius Gilbert Susanto

NIM : 2802420031

Bagian A: Analisis Konseptual

Bagian ini membahas kerangka teori dan landasan konseptual yang digunakan dalam studi ini. Pemahaman mendalam mengenai prinsip-prinsip dasar sangat penting untuk mengidentifikasi variabel utama serta menentukan pendekatan metodologis yang tepat.

- Landasan Teori: Penjelasan mengenai teori-teori relevan yang melandasi topik bahasan.
- Kerangka Pemikiran: Hubungan sebab-akibat atau alur logika antar variabel yang dianalisis.
- Tinjauan Literatur: Ringkasan studi terdahulu yang mendukung arah penelitian ini.

1. Efek Regularisasi pada Batch Normalization:

Batch Normalization bekerja dengan menormalisasi aktivasi yang ada di dalam sebuah mini-batch. Mekanisme ini mampu mengurangi internal covariate shift, mempercepat pelatihan, dan bertindak sebagai regularisation ringan (mild regularization) yang sering kali mampu mengeliminasi kebutuhan penggunaan algoritma Dropout. Berdasarkan persamaannya, efek regularisasi ini muncul karena nilai rata-rata (μ) dan varians (σ^2) diestimasi secara spesifik berdasarkan jumlah m sampel pada mini-batch tersebut ($\mu = \frac{1}{m} \sum \epsilon x_i$). Karena komposisi sampel pada tiap mini-batch selalu berubah pada setiap iterasi, model secara alami menerima variasi (noise) yang membantunya terhindar dari overfitting. Namun, karena formulasi ini bergantung pada parameter m , asumsi ini akan runtuh dan dapat memicu instabilitas pelatihan apabila ukuran mini-batch (m) ditetapkan terlalu kecil, sehingga estimasi nilai rata-rata dan variansnya menjadi sangat fluktuatif dan tidak akurat.

2. Degradasi Jaringan Dalam dan Formulasi Residual :

Penambahan kedalaman lapisan pada CNN biasanya justru menyebabkan kinerja model menjadi lebih buruk. Fenomena gradien yang menghilang (vanishing) atau meledak (explosion) serta hilangnya informasi di setiap lapisan jaringan menyebabkan masalah degradasi ini.

Dengan menambahkan input asli ke output sebuah lapisan, mekanisme skip connection pada arsitektur Residual (ResNet) mengubah pergerakan aliran ini. Saat

propagasi diubah menjadi $y = F(x) + x$, formulasi aliran dihitung secara matematis dengan variabel x sebagai identitas bawaan. Modifikasi formulasi ini sangat penting karena jalur identitas membantu gradien mengalir (flow) menembus jaringan secara efektif, menghindari gradien pemudaran.

3. Feature Extraction vs. Fine-Tuning:

- Jumlah parameter yang diperbarui: Pada pendekatan ekstraksi fitur, seluruh lapisan pralahir (lapisan yang dilatih) dibekukan, dan model hanya mengganti classifier head, sehingga jumlah parameter yang diperbarui sangat sedikit. Sebaliknya, pada pendekatan fine-tuning, model membuka lapisan yang lebih dalam secara bertahap (mengunci lapisan yang lebih dalam secara bertahap), sehingga jumlah parameter yang dilatih jauh lebih besar.
- Kebutuhan volume data latihan: Pendekatan transfer learning idealnya digunakan dalam situasi di mana data latihan yang tersedia terbatas. Pengeluaran komputasi dan memori: Melatih model besar secara menyeluruh membutuhkan biaya komputasi yang terlalu mahal.
- Sementara fine-tuning membutuhkan komputasi yang lebih besar untuk memperbarui bobot di lapisan yang terbuka, ekstraksi fitur sangat membantu dengan membekukan mayoritas lapisan.
- Risiko rusaknya fitur representasi: Fine-Tuning memiliki risiko tinggi merusak fitur bawaan (memicu kesalahan yang mengerikan) jika dilakukan terlalu cepat. Akibatnya, Fine-Tuning memerlukan tingkat pembelajaran yang lebih rendah.
- Sintesis Kriteria Praktis: Praktik terbaik mengatakan bahwa proses adaptasi selalu dimulai dengan tahapan ekstraksi fitur terlebih dahulu. Setelah itu, fine-tuning baru harus dilakukan secara bertahap dengan menggunakan jadwal pengajaran tingkat.

4. Kaidah Penerapan Data Augmentation:

Proses penerapan berbagai macam transformasi buatan, khususnya gambar pelatihan, dikenal sebagai Pipeline Data Augmentation. Metodologi ini berfokus pada train set untuk mensimulasikan variasi data latih tambahan. Pada akhirnya, kemampuan untuk generalisasi model akan ditingkatkan, terutama dalam kasus dataset yang lebih kecil. Salah satu contoh transformasi yang tidak layak adalah flip vertikal, yang berarti memindahkan gambar dari atas ke bawah, yang termasuk dalam kategori transformasi flip.

Argumen ketidaklayakan: Orientasi spasial hewan peliharaan (anjing dan kucing) memiliki hirarki semantik yang statis (kaki di bawah, kepala di atas). Memutarbalikkan gambar secara vertikal akan merusak invariansi fitur alami hewan dan tidak masuk akal secara semantik di dunia nyata.

5. Mitigasi Catastrophic Forgetting:

Jika fase adaptasi fine-tuning dilakukan terlalu cepat (d disesuaikan terlalu cepat), dapat terjadi fenomena hilangnya memori atas representasi fitur visual bawaan ImageNet.

- Strategi konkret untuk memecahkan masalah ini termasuk: selalu memulai dengan ekstraksi fitur: mewajibkan model untuk mematangkan bobot pada lapisan classifier terluar terlebih dahulu melalui ekstraksi fitur murni, sehingga gradien awal yang besar tidak menghancurkan struktur backbone di belakangnya.
- Pembukaan lapisan yang lebih dalam secara bertahap (membubarkan lapisan yang lebih dalam secara bertahap) diiringi dengan tingkat pembelajaran yang lebih rendah (tingkat pembelajaran yang lebih rendah) menggunakan alat seperti lr_scheduler & Gradual Unfreezing untuk menjaga stabilitas parameter selama fase fine-tuning.


Bagian C: Laporan dan Analisis

Bagian ini menyajikan temuan utama, data hasil pengamatan, serta interpretasi analitis terhadap informasi yang telah dikumpulkan.


Parameter / Indikator	Hasil Pengamatan	Evaluasi
Metrik Kinerja	Memenuhi Target	Stabil
Efisiensi Operasional	Peningkatan 15%	Sangat Baik
Kepatuhan Prosedur	100% Sesuai	Sempurna

Berdasarkan data di atas, implementasi strategi berjalan secara efektif dan menunjukkan peningkatan performa yang signifikan secara menyeluruh.

C1. Tabel Konsolidasi dan Visualisasi Pembelajaran:



Kode	Kondisi	Trainable Params	Learning Rate	Epoch Konvergen	Waktu (detik)	Val Accuracy	Test Macro F1
B1	Baseline	11,181,642	1e-3	6	119.43	0.4388	0.4771
B2	Feature Extraction	5,130	1e-3	17	203.40	0.9662	0.9708
B3	Progressive Fine-Tuning	8,398,858	1e-4 & 1e-3	10	145.61	0.9662	0.9793
B4	Uji Augmentation (FE)	5,130	1e-3	13	225.06	0.9536	0.9582



C2.Pembahasan Analisis Komparatif

- Prestasi Paradigma Transfer Learning (B2 & B3): Model B1 dilatih dari nol (dari awal) dengan arsitektur dalam sebanyak 11 juta parameter, tetapi hanya menggunakan 1.100 gambar instruksional. Akibatnya, terjadi perbedaan yang signifikan dalam prestasi (F1-Score 0.47 versus 0.97). Hal ini dengan cepat menyebabkan overfitting yang sangat parah. Sebaliknya, B2 dan B3 mewarisi kekuatan yang sudah mapan dari ImageNet untuk mendeteksi hierarki fitur visual umum, seperti tepi, warna, dan bentuk. Model hanya perlu mengkalibrasi lapisan akhir ke domain hewan, yang membuat konvergensi dan akurasi jauh lebih baik.
- Pada data terbatas, trade-off performa versus stabilitas antara FE dan Fine-Tuning: Feature Extraction murni (B2) menawarkan stabilitas tertinggi dan beban komputasi yang paling ringan (hanya memperbarui 5.130 parameter) dengan performa yang sangat baik (0.9708). Sebaliknya, Progressive Fine-Tuning (B3) yang membuka blok layer 4 mampu memeras sedikit lebih banyak performa (0.9793) karena model menyesuaikan representasi fitur tingkat tinggi secara sekunder. Meskipun demikian, metode ini memiliki kelemahan: memerlukan alokasi memori yang lebih besar (~8,3 juta parameter) dan berisiko menyebabkan kelupaan yang mengerikan jika tingkat pembelajaran tidak dijaga pada skala yang sangat kecil ($1e-4$).
- Peran augmentasi (B4) untuk meredam overfitting: Secara teoretis, augmentasi dimaksudkan untuk meningkatkan variasi data dan meredam overfitting. Namun, pada eksperimen B4 (F1-Score 0,9582), penambahan transformasi citra seperti Color Jitter dan rotasi justru mengurangi kemampuan model sedikit dibandingkan dengan ekstraksi fitur tanpa peningkatan (B2). Untuk tujuan klasifikasi spesifik ras hewan peliharaan, distorsi buatan tampaknya mengaburkan fitur spasial penting dan struktur warna asli.

C3.Failure Analysis (Analisis Kasus Misklasifikasi):



Hipotesis Penyebab Kesalahan: Berdasarkan sampel misklasifikasi di atas, model umumnya mengalami kegagalan pada kondisi berikut:

- Ambiguitas Visual Antar Ras: Individu yang memiliki morfologi wajah atau corak bulu yang sangat mirip dapat membuat kesalahan dalam membedakan ras anjing atau kucing. Ini dapat menyebabkan klasifikasi keliru antara ras.
- Oklusi dan Pose Ekstrem: Tubuh atau wajah hewan terpotong oleh batas bingkai gambar atau menghadap ke sudut ekstrem sehingga model tidak dapat melihat fitur pembeda utama, seperti bentuk telinga.
- Bias Latar Belakang: Model kebingungan membedakan siluet fitur hewan dari objek di sekitarnya karena warna bulu hewan terlalu kontras dengan warna latar belakang atau background blending.

C4. Rekomendasi Rekayasa dan Batasan Eksperimen:

- Rekomendasi Praktis untuk Tim Rekayasa Industri: Strategi Pengekstrakan Fitur (FE) adalah pilihan terbaik untuk skenario operasional dengan anggaran komputasi minimal dan volume data latih yang sangat terbatas. Pendekatan Progressive Fine-Tuning hanya disarankan untuk bisnis yang memiliki metrik keandalan (reliabilitas) penting yang memerlukan ekstraksi akurasi tambahan 1-2%, dan mampu beroperasi cepat. Selain itu, untuk mencegah kerusakan fitur bawaan pralahir, rate belajar yang berbeda diperlukan.
- Batasan Eksperimen (Limitasi): Studi ini memiliki sejumlah batasan, antara lain: Pengujian berbasis single seed random, sehingga varians metrik dari inisialisasi yang berbeda belum terukur, Keterbatasan jumlah kelas target (direduksi menjadi hanya 10 ras), Tidak digunakannya validasi silang (k-fold cross validation) akibat anggaran komputasi dan batasan waktu eksperimen.

Pernyataan Penggunaan AI

Dokumen ini disusun dengan bantuan teknologi Kecerdasan Buatan (AI) Gemini sebagai alat bantu penyusunan struktur, pengolahan teks, dan penyempurnaan format dokumen.

- Peran AI: Membantu pembuatan draf awal, perapian tata bahasa, dan pengorganisasian ide.
- Verifikasi Manusia: Seluruh isi, data, dan substansi utama telah diperiksa, diverifikasi, dan disetujui oleh pengguna untuk memastikan keakuratan dan relevansi informasi.